

混合分布と教師なし学習 (復習)

正田 備也

masada@rikkyo.ac.jp

Contents

混合分布モデルの教師なし学習

混合正規分布モデルの教師なし学習

変分ベイズ法とは

混合分布

- ▶ 観測データの集まりを、いくつかのまとまりに分けられそうな場合、混合分布をデータのモデリングに用いる
 - ▶ そのまとまりのことを、以下、「コンポーネント」と呼ぶ
- ▶ 各々の観測データ x_i が、どのコンポーネントに属するか、すでに分かっている場合は、教師あり学習をおこなう
 - ▶ これは、分類 (classification)
- ▶ 各々の観測データ x_i が、どのコンポーネントに属するか、不明な場合は、教師なし学習をおこなう
 - ▶ これは、クラスタリング (clustering)




Figure: 2次元ベクトルの集合をモデリングする混合分布の例

混合分布モデルを指定する

- ▶ 混合分布のコンポーネントについて、以下を指定する
 - ▶ コンポーネントの数を決める（この個数を K とする）
 - ▶ 各コンポーネントに対応する分布を決める（例：正規分布）
- ▶ 各々の観測データ \mathbf{x}_i がどのコンポーネントへ属するかを表す確率変数を z_i とすると、同時分布 $p(\mathcal{X}, \mathcal{Z})$ は

$$p(\mathcal{X}, \mathcal{Z}) = \prod_{i=1}^N p(\mathbf{x}_i, z_i) = \prod_{i=1}^N p(z_i)p(\mathbf{x}_i|z_i) \quad (1)$$

- ▶ ただし、 $\mathcal{X} \equiv \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, $\mathcal{Z} \equiv \{z_1, \dots, z_N\}$ と定義した
- ▶ $z_i = k$ は \mathbf{x}_i が k 番目のコンポーネントに属することを意味する

混合分布によるデータの生成

- ▶ 混合分布を使ったモデリングでは、 N 個の観測データ $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ が以下のように生成されると仮定する
 1. カテゴリカル分布 $\text{Cat}(\boldsymbol{\theta})$ から、確率変数 z_i の値を draw する
 - ▶ 「 $z_i = k$ 」は、 \mathbf{x}_i が k 番目のコンポーネントに属する、という意味
 2. z_i 番目のコンポーネントに対応する確率分布から、確率変数 \mathbf{x}_i の値を draw する
- ▶ 与えられた観測データがこのように生成されたとしたら、モデルのパラメータがいくらになるか、推定したい

混合分布モデルの教師なし学習

- ▶ 各 z_i がその値の分からない確率変数、つまり潜在変数(latent variable)である場合、教師なし学習をおこなう
- ▶ 潜在変数 $\mathcal{Z} = \{z_1, \dots, z_N\}$ を、周辺化 $\sum_{\mathcal{Z}} p(\mathcal{X}, \mathcal{Z})$ によって消去し、観測データの尤度 $p(\mathcal{X})$ を得る
- ▶ そしてデータの尤度 $p(\mathcal{X})$ を最大化する、という問題を解く
 - ▶ 通常は対数尤度 $\ln p(\mathcal{X})$ を最大化する
- ▶ この最大化問題を解くことで、(a) 各データ x_i が K 個のコンポーネント各々へ所属する確率と、(b) 各コンポーネントに対応する確率分布のパラメータを推定する

Contents

混合分布モデルの教師なし学習

混合正規分布モデルの教師なし学習

変分ベイズ法とは

混合正規分布によるデータの生成

- ▶ 混合正規分布を使ったモデリングでは、 N 個の観測データ $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ が独立に以下のように生成されると仮定する
- 1. カテゴリカル分布 $\text{Cat}(\boldsymbol{\theta})$ から、確率変数 z_i の値を draw する
 - ▶ 「 $z_i = k$ 」は、 \mathbf{x}_i が k 番目のコンポーネントに属する、という意味
- 2. その z_i の値に対応する正規分布から、 \mathbf{x}_i の値を draw する
 - ▶ 第 k コンポーネントを表す正規分布のパラメータを $\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k$ とする

$$z_i \sim \text{Cat}(\boldsymbol{\theta})$$

$$\mathbf{x}_i \sim \mathcal{N}(\boldsymbol{\mu}_{z_i}, \boldsymbol{\Sigma}_{z_i}) \quad (2)$$

単変量正規分布の混合分布のパラメータ

- ▶ K 個のコンポーネントから一つを選ぶ際に使われるカテゴリカル分布のパラメータを $\boldsymbol{\theta} = (\theta_1, \dots, \theta_K)$ とする
 - ▶ θ_k は k 番目のコンポーネントが選ばれる確率 ($\sum_{k=1}^K \theta_k = 1$)

$$p(z; \boldsymbol{\theta}) = \prod_{k=1}^K \theta_k^{\delta(z=k)} = \theta_z \quad (3)$$

- ▶ k 番目のコンポーネントを表す正規分布の平均パラメータを μ_k とし、標準偏差パラメータを σ_k とする

$$p(x|z; \mu_z, \sigma_z) = \frac{1}{\sqrt{2\pi\sigma_z^2}} \exp\left(-\frac{(x - \mu_z)^2}{2\sigma_z^2}\right) \quad (4)$$

単変量正規分布の混合分布の場合の同時分布

- ▶ $\mathcal{X} = \{x_1, \dots, x_N\}$ と $\mathcal{Z} = \{z_1, \dots, z_N\}$ との同時分布は

$$\begin{aligned} p(\mathcal{X}, \mathcal{Z}; \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\}) &= \prod_{i=1}^N p(z_i; \boldsymbol{\theta}) p(x_i | z_i; \mu_{z_i}, \sigma_{z_i}) \\ &= \prod_{i=1}^N \left[\theta_{z_i} \times \frac{1}{\sqrt{2\pi\sigma_{z_i}^2}} \exp \left(-\frac{(x_i - \mu_{z_i})^2}{2\sigma_{z_i}^2} \right) \right] \end{aligned} \quad (5)$$

- ▶ $p(z_i; \boldsymbol{\theta})$ はカテゴリカル分布 $\text{Cat}(\boldsymbol{\theta})$ の pmf から求まる z_i の尤度
- ▶ $p(x_i | z_i; \mu_{z_i}, \sigma_{z_i})$ は正規分布 $\mathcal{N}(\mu_{z_i}, \sigma_{z_i})$ の pdf から求まる x_i の尤度

混合正規分布モデルの教師なし学習

- ▶ 各データ x_i がどのコンポーネントから生成されたか分からない場合、 z_i は潜在変数 (latent variable) となる
- ▶ このとき、教師なし学習をおこなう
- ▶ 観測変数と潜在変数の同時分布 $p(\mathcal{X}, \mathcal{Z})$ は、式 (5) のとおり

$$\begin{aligned} p(\mathcal{X}, \mathcal{Z}; \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\}) &= \prod_{i=1}^N p(z_i; \boldsymbol{\theta}) p(x_i | z_i; \mu_{z_i}, \sigma_{z_i}) \\ &= \prod_{i=1}^N \left[\theta_{z_i} \times \frac{1}{\sqrt{2\pi\sigma_{z_i}^2}} \exp \left(-\frac{(x_i - \mu_{z_i})^2}{2\sigma_{z_i}^2} \right) \right] \end{aligned}$$

観測データの尤度

- ▶ 潜在変数 \mathcal{Z} を周辺化することによって、観測データの尤度 $p(\mathcal{X}; \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\})$ を得る
 - ▶ 周辺化 = 潜在変数の値の全ての場合 (K^N 通り) について和をとる

$$\begin{aligned} p(\mathcal{X}) &= \sum_{\mathcal{Z}} p(\mathcal{X}, \mathcal{Z}) = \sum_{z_1=1}^K \sum_{z_2=1}^K \cdots \sum_{z_{N-1}=1}^K \sum_{z_N=1}^K p(\mathcal{X}, \mathcal{Z}) \\ &= \sum_{z_1=1}^K \sum_{z_2=1}^K \cdots \sum_{z_{N-1}=1}^K \sum_{z_N=1}^K \prod_{i=1}^N p(x_i, z_i) \\ &= \prod_{i=1}^N \left(\sum_{z_i=1}^K p(x_i, z_i) \right) = \prod_{i=1}^N \left(\sum_{z_i=1}^K p(z_i) p(x_i | z_i) \right) \quad (6) \end{aligned}$$

観測データの対数尤度

- ▶ よって、観測データ \mathcal{X} の対数尤度は、式 (5) と式 (6) より

$$\begin{aligned}\ln p(\mathcal{X}) &= \ln \sum_{\mathcal{Z}} p(\mathcal{X}, \mathcal{Z}) = \ln \prod_{i=1}^N \left(\sum_{z_i=1}^K p(x_i, z_i) \right) \\ &= \ln \prod_{i=1}^N \left(\sum_{z_i=1}^K p(z_i) p(x_i | z_i) \right) = \sum_{i=1}^N \ln \left(\sum_{z_i=1}^K p(z_i) p(x_i | z_i) \right) \\ &= \sum_{i=1}^N \ln \left(\sum_{z_i=1}^K \left[\theta_{z_i} \times \frac{1}{\sqrt{2\pi\sigma_{z_i}^2}} \exp \left(-\frac{(x_i - \mu_{z_i})^2}{2\sigma_{z_i}^2} \right) \right] \right) \quad (7)\end{aligned}$$

対数尤度の最大化によるパラメータ推定

- ▶ あとは、対数尤度 $\ln p(\mathcal{X}) = \sum_{i=1}^N \ln \left(\sum_{z_i=1}^K p(z_i) p(x_i|z_i) \right)$ を最大にする $\theta = (\theta_1, \dots, \theta_K)$ や μ_1, \dots, μ_K や $\sigma_1, \dots, \sigma_K$ を求めれば良い・・・???
- ▶ 通常、式(7)をそのまま最大化することはない
- ▶ EM アルゴリズムを使う

積の対数と和の対数

- ▶ 何かを掛け算したものの対数は、何かの対数の和に書き直せるので、扱いやすい

$$\log(a \times b) = \log(a) + \log(b) \quad (8)$$

- ▶ 何かを足し算したものの対数は、それ以上変形のしようがないので、扱いにくい

$$\log(a + b) = \dots \quad (9)$$

イェンセン Jensen の不等式（対数関数の場合）

- ▶ p_1, \dots, p_K を、 $\sum_{k=1}^K p_k = 1$ を満たす正の実数とする
- ▶ a_1, \dots, a_K を任意の正の実数とする
- ▶ このとき、以下の不等式が成り立つ

$$\ln \left(\sum_{k=1}^K p_k a_k \right) \geq \sum_{k=1}^K p_k \ln(a_k) \quad (10)$$

- ▶ 和の対数（扱いにくい！）の下界 (lower bound) を、対数の和（扱いやすい！）として得るため、イェンセンの不等式をよく使う
- ▶ なお、対数関数に限らず、上に凸な関数なら、上の不等式は成立

対数尤度の下界

- ▶ イェンセンの不等式を利用して $\ln p(\mathcal{X})$ の下界を得たい
- ▶ そこで、各観測データ x_i について $\mathbf{q}_i \equiv (q_{i,1}, \dots, q_{i,K})$ という $\sum_{k=1}^K q_{i,k} = 1$ を満たす潜在変数を用意すると、式(7)より

$$\begin{aligned}\ln p(\mathcal{X}) &= \sum_{i=1}^N \ln \left(\sum_{z_i=1}^K p(z_i) p(x_i|z_i) \right) \\ &= \sum_{i=1}^N \ln \left(\sum_{z_i=1}^K q_{i,z_i} \frac{p(z_i) p(x_i|z_i)}{q_{i,z_i}} \right) \geq \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{p(z_i) p(x_i|z_i)}{q_{i,z_i}}\end{aligned}\tag{11}$$

- ▶ この下界を $\mathcal{L}(\{\mathbf{q}_i\}, \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\})$ と書くことにする

$$\ln p(\mathcal{X}) \geq \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{p(z_i)p(x_i|z_i)}{q_{i,z_i}} \equiv \mathcal{L}(\{\mathbf{q}_i\}, \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\}) \quad (12)$$

▶ この下界は以下のようにも書ける

$$\begin{aligned} & \mathcal{L}(\{\mathbf{q}_i\}, \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\}) \\ &= \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln p(z_i)p(x_i|z_i) - \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln q_{i,z_i} \end{aligned} \quad (13)$$

対数尤度の下界の最大化

- ▶ $\ln p(\mathcal{X})$ の代わりに $\mathcal{L}(\{\mathbf{q}_i\}, \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\})$ を最大化することによって、次の未知量を推定する
 - ▶ 新たに導入した $\{\mathbf{q}_i\} \equiv \{\mathbf{q}_1, \dots, \mathbf{q}_N\}$ where $\mathbf{q}_i = (q_{i,1}, \dots, q_{i,K})$
 - ▶ モデルパラメータ $\Theta \equiv \{\boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\}\}$
- ▶ 単変量正規分布の混合分布の場合 (cf. 式(3)、式(4))

$$p(z_i = k) = \theta_k \quad (14)$$

$$p(x_i | z_i = k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right) \quad (15)$$

- ▶ これらを式(13)に当てはめることで、以下、推定計算を行う

$$\begin{aligned}
& L(\{\mathbf{q}_i\}, \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\}) \\
&= \mathcal{L}(\{\mathbf{q}_i\}, \boldsymbol{\theta}, \{\mu_k\}, \{\sigma_k\}) + \sum_{i=1}^N \lambda_i \left(1 - \sum_{k=1}^K q_{i,k}\right) + \lambda_0 \left(1 - \sum_{k=1}^K \theta_k\right) \\
&= \sum_{i=1}^N \sum_{k=1}^K q_{i,k} \ln \frac{\theta_k p(x_i | z_i = k)}{q_{i,k}} + \sum_{i=1}^N \lambda_i \left(1 - \sum_{k=1}^K q_{i,k}\right) + \lambda_0 \left(1 - \sum_{k=1}^K \theta_k\right) \\
&= \sum_{i=1}^N \sum_{k=1}^K q_{i,k} \ln (\theta_k p(x_i | z_i = k)) - \sum_{i=1}^N \sum_{k=1}^K q_{i,k} \ln q_{i,k} + \sum_{i=1}^N \lambda_i \left(1 - \sum_{k=1}^K q_{i,k}\right) + \lambda_0 \left(1 - \sum_{k=1}^K \theta_k\right)
\end{aligned} \tag{16}$$

$$\frac{\partial L}{\partial q_{i,k}} = \ln (\theta_k p(x_i | z_i = k)) - \ln q_{i,k} - 1 - \lambda_i \tag{17}$$

$\frac{\partial L}{\partial q_{i,k}} = 0$ と $\sum_k q_{i,k} = 1$ より $q_{i,k} = \frac{\theta_k p(x_i | z_i = k)}{\sum_{k'} \theta_{k'} p(x_i | z_i = k')}$ を得る。

$q_{i,k} \ln (\theta_k p(x_i|z_i = k)) = q_{i,k} \ln \theta_k + q_{i,k} \ln p(x_i|z_i = k)$ より、

$$\frac{\partial L}{\partial \theta_k} = \frac{\sum_{i=1}^N q_{i,k}}{\theta_k} - \lambda_0 \quad (18)$$

$\frac{\partial L}{\partial \theta_k} = 0$ と $\sum_k \theta_k = 1$ より $\theta_k = \frac{\sum_{i=1}^N q_{i,k}}{\sum_{k=1}^K \sum_{i=1}^N q_{i,k}} = \frac{\sum_{i=1}^N q_{i,k}}{N}$ を得る。

$\frac{\partial}{\partial \mu_k} \ln p(x_i|z_i = k) = \frac{x_i - \mu_k}{\sigma_k^2}$ と $\frac{\partial}{\partial \sigma_k} \ln p(x_i|z_i = k) = -\frac{1}{\sigma_k} + \frac{(x_i - \mu_k)^2}{\sigma_k^3}$ より

$$\frac{\partial L}{\partial \mu_k} = \frac{\sum_{i=1}^N q_{i,k} (x_i - \mu_k)}{\sigma_k^2} \quad (19)$$

$$\frac{\partial L}{\partial \sigma_k} = \frac{\sum_{i=1}^N q_{i,k} (-\sigma_k^2 + (x_i - \mu_k)^2)}{\sigma_k^3} \quad (20)$$

$\frac{\partial L}{\partial \mu_k} = 0$ より $\mu_k = \frac{\sum_{i=1}^N q_{i,k} x_i}{\sum_{i=1}^N q_{i,k}}$ を得る。また、 $\frac{\partial L}{\partial \sigma_k} = 0$ より $\sigma_k^2 = \frac{\sum_{i=1}^N q_{i,k} (x_i - \mu_k)^2}{\sum_{i=1}^N q_{i,k}}$ を得る。

混合正規分布のEMアルゴリズム

▶ E step

$$q_{i,k} \leftarrow \frac{\theta_k p(x_i | z_i = k)}{\sum_{k'} \theta_{k'} p(x_i | z_i = k')} \quad (21)$$

ただし $p(x_i | z_i = k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right)$

▶ M step

$$\theta_k \leftarrow \frac{\sum_{i=1}^N q_{i,k}}{N} \quad (22)$$

$$\mu_k \leftarrow \frac{\sum_{i=1}^N q_{i,k} x_i}{\sum_{i=1}^N q_{i,k}} \quad (23)$$

$$\sigma_k^2 \leftarrow \frac{\sum_{i=1}^N q_{i,k} (x_i - \mu_k)^2}{\sum_{i=1}^N q_{i,k}} \quad (24)$$

$q_{i,k}$ とは何なのか (1/4)

- ▶ イェンセンの不等式を使って、次の下界を得たのだった

$$\sum_{i=1}^N \ln \left(\sum_{z_i=1}^K p(z_i)p(x_i|z_i) \right) \geq \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{p(z_i)p(x_i|z_i)}{q_{i,z_i}}$$

- ▶ 左辺から右辺を引くと

$$\begin{aligned} & \sum_{i=1}^N \ln \left(\sum_{z_i=1}^K p(z_i)p(x_i|z_i) \right) - \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{p(z_i)p(x_i|z_i)}{q_{i,z_i}} \\ &= \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \left(\sum_{z_i=1}^K p(z_i)p(x_i|z_i) \right) - \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{p(z_i)p(x_i|z_i)}{q_{i,z_i}} \end{aligned}$$

$q_{i,k}$ とは何なのか (2/4)

(続き)

$$\begin{aligned} &= \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \left(\sum_{z_i=1}^K p(x_i, z_i) \right) - \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{p(z_i)p(x_i|z_i)}{q_{i,z_i}} \\ &= \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln p(x_i) - \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{p(x_i, z_i)}{q_{i,z_i}} \\ &= \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{p(x_i)q_{i,k}}{p(x_i, z_i)} = \sum_{i=1}^N \sum_{z_i=1}^K q_{i,z_i} \ln \frac{q_{i,z_i}}{p(z_i|x_i)} \end{aligned} \quad (25)$$

► $q_{i,k} = p(z_i = k|x_i)$ のとき、等号が成立する

カルバック・ライブラー情報量

- ▶ p, q を離散確率分布とすると、 q から p への (p の q に対する) カルバック・ライブラー情報量 Kullback – Leibler divergence とは

$$D_{\text{KL}}(p \parallel q) = \sum_x p(x) \ln \frac{p(x)}{q(x)} \quad (26)$$

- ▶ p, q が連続確率分布の場合は

$$D_{\text{KL}}(p \parallel q) = \int p(x) \ln \left(\frac{p(x)}{q(x)} \right) dx \quad (27)$$

- ▶ $p = q$ ならば、またそのときに限り $D_{\text{KL}}(p \parallel q) = 0$

注. $q(x) = 0$ なのに $p(x) \neq 0$ となる x があってはいけない！

$q_{i,k}$ とは何なのか (3/4)

- ▶ $q_i(z_i)$ を、 K 個のアイテム $\{1, \dots, K\}$ 上に定義されたカテゴリカル分布とし、 $q_i(z_i = k) \equiv q_{i,k}$ と設定する
- ▶ 式 (25) は $q_i(z_i)$ の $p(z_i|x_i)$ に対するカルバック・ライブラー情報量になっている
- ▶ ところで、式 (21) より、

$$\begin{aligned} q_{i,k} &= \frac{\theta_k p(x_i|z_i = k)}{\sum_{k'} \theta_{k'} p(x_i|z_i = k')} = \frac{p(z_i = k) p(x_i|z_i = k)}{\sum_{k'} p(z_i = k') p(x_i|z_i = k')} \\ &= \frac{p(x_i, z_i = k)}{\sum_{k'} p(x_i, z_i = k')} = \frac{p(x_i, z_i = k)}{p(x_i)} = p(z_i = k|x_i) \quad (28) \end{aligned}$$

$q_{i,k}$ とは何なのか (4/4)

- ▶ つまり、式 (21) は $q_{i,k} = p(z_i = k|x_i)$ を意味している
- ▶ このとき、式 (25) のカルバック・ライブラー情報量はゼロ！
- ▶ ということは、Eステップで得られる $q_{i,k}$ は、最善の答え
- ▶ ただし、この $q_{i,k}$ は、パラメータ $\theta, \{\mu_k\}, \{\sigma_k\}$ の値を特定の値に固定した上で、 $\ln p(x_i)$ の下界を最大化して求めたもの
- ▶ Mステップでは、逆に $\{\mathbf{q}_i\}$ のほうを固定し、 $\ln p(x_i)$ の下界を最大化している

E stepで何をしているか

- ▶ モデルのパラメータ $\Theta \equiv \{\theta, \mu_1, \dots, \mu_K, \sigma_1, \dots, \sigma_K\}$ の値を固定した状態で、対数尤度の下界を最大化する $\{q_i\}$ を求めているのが、E step
- ▶ パラメータ Θ の、固定された値を、 Θ_{old} と書くことにする
- ▶ その最大化によって得られる答えは

$$q_{i,k} = p(z_i = k | x_i; \Theta_{\text{old}}) \quad (29)$$

- ▶ つまり、モデルパラメータ Θ の値を固定したうえで、観測データを所与とする潜在変数の条件付き分布を求めている

ここまでの議論のパターン

- ▶ 確率モデルが潜在変数 \mathcal{Z} を含む
- ▶ モデルを指定することで観測データと潜在変数の同時分布 $p(\mathcal{X}, \mathcal{Z})$ の式を得る
- ▶ 潜在変数 \mathcal{Z} の周辺化 $\sum_{\mathcal{Z}} p(\mathcal{X}, \mathcal{Z})$ により観測データの尤度 $p(\mathcal{X})$ が得られるが、実際にはこの尤度は計算できない
- ▶ Jensen の不等式を使い、対数尤度 $\ln p(\mathcal{X})$ の下界を得る
- ▶ この下界を最大化することで、様々な未知量を推定する

Contents

混合分布モデルの教師なし学習

混合正規分布モデルの教師なし学習

変分ベイズ法とは

ベイズ的モデリングにおける変分法

- ▶ 観測データを表す確率変数を $\mathcal{X} \equiv \{x_1, \dots, x_N\}$ とする
- ▶ データモデルのパラメータを Θ とする
- ▶ ベイズ的なモデリングでは、 \mathcal{X} だけでなく Θ も確率変数
- ▶ ベイズ的なモデリングで知りたいのは、事後分布 $p(\Theta|\mathcal{X})$

$$p(\Theta|\mathcal{X}) = \frac{p(\mathcal{X}|\Theta)p(\Theta)}{p(\mathcal{X})} \quad (30)$$

- ▶ 変分ベイズ法は $p(\Theta|\mathcal{X})$ を近似する分布 $q(\Theta)$ を求める
 - ▶ $q(\Theta)$ を変分法 (variational methods) で求める (後述)
 - ▶ $q(\Theta)$ を変分事後分布 (variational posterior distribution) と呼ぶ

先ほどまでの議論のパターンを適用

- ▶ 確率モデルが Θ という潜在変数を含む
 - ▶ ベイズの枠組みの中では、モデルパラメータ Θ は確率変数だから、 Θ はその値が見えていない確率変数、つまり、潜在変数になる
- ▶ ベイズ的なモデルを指定することで観測データと潜在変数の同時分布 $p(\mathcal{X}, \Theta)$ の式を得る
- ▶ 潜在変数 Θ の周辺化 $\int p(\mathcal{X}, \Theta) d\Theta$ により観測データの尤度 $p(\mathcal{X})$ が得られるが、実際にはこの尤度は計算できない
- ▶ Jensen の不等式を使い、対数尤度 $\ln p(\mathcal{X})$ の下界を得る
- ▶ この下界を最大化することで、様々な未知量を推定する

変分ベイズ法 (variational Bayesian methods)

- ▶ 潜在変数を含むモデルの対数尤度最大化の話と似ている
- ▶ その値が見えている確率変数 \mathcal{X} と、その値が見えていない確率変数 Θ とがある
- ▶ $p(\mathcal{X}, \Theta)$ は式で書けるが、 $p(\mathcal{X}) = \int p(\mathcal{X}, \Theta) d\Theta$ は書けない
- ▶ $\ln p(\mathcal{X})$ の代わりに、 $\ln p(\mathcal{X})$ の下界を最大化する
- ▶ $\ln p(\mathcal{X})$ の下界は Jensen の不等式を使って求める

$$\ln p(\mathcal{X}) = \ln \int q(\Theta) \frac{p(\mathcal{X}, \Theta)}{q(\Theta)} d\Theta \geq \int q(\Theta) \ln \frac{p(\mathcal{X}, \Theta)}{q(\Theta)} d\Theta$$

- ▶ この $q(\Theta)$ が変分事後分布

「変分 (variational)」の意味

- ▶ ELBO の最大化は、 $q(\Theta)$ を変化させることでおこなう
- ▶ $q(\Theta)$ の密度関数がどんなかたちを持つかに制約を設けない
- ▶ 逆に言うと、 $q(\Theta)$ の密度関数が特定のかたちを持つと仮定した上で、その関数のパラメータだけを動かすのではない
 - ▶ パラメータについて微分することで最大化問題を解くのではなく、いわば “関数について微分する” ことで最大化問題を解いている
- ▶ とても直感的に言うと、関数のかたちを決めてそのパラメータを動かすのではなく、関数のかたち自体を動かすことで問題を解く方法を、変分法と呼ぶ (cf. 汎関数微分)