

混合分布モデルのベイズ化

正田 備也

masada@rikkyo.ac.jp

Contents

混合分布モデル

混合分布モデルのベイズ化

例：混合ポアソン分布モデルのベイズ化

混合分布

- ▶ 観測データの集まりを、いくつかのまとまりに分けられそうな場合、混合分布をデータのモデリングに用いる
 - ▶ そのまとまりのことを、以下、「コンポーネント」と呼ぶ
- ▶ 各々の観測データ x_i が、どのコンポーネントに属するか、すでに分かっている場合は、教師あり学習をおこなう
 - ▶ これは、分類 (classification)
- ▶ 各々の観測データ x_i が、どのコンポーネントに属するか、不明な場合は、教師なし学習をおこなう
 - ▶ これは、クラスタリング (clustering) ← 今回の設定はこちら




Figure: 2次元ベクトルの集合をモデリングする混合分布の例

混合分布モデルを指定する

- ▶ 以下の2点を決めることにより混合分布モデルを指定できる

1. コンポーネントの個数 K を決める

- ▶ k 番目のコンポーネントが選ばれる確率を θ_k と書くことにする
- ▶ $(\theta_1, \dots, \theta_K)$ を θ と書くことにする ($\sum_k \theta_k = 1$ を満たす)

2. 各コンポーネントを表す分布を決める

- ▶ 全てのコンポーネントは同じ確率分布（例：正規分布）で表され、パラメータの値が違うだけだとすることが多い
- ▶ k 番目のコンポーネントを表す確率分布のパラメータを ϕ_k と書くことにする（例：単変量正規分布の場合は $\phi_k = (\mu_k, \sigma_k)$ ）
- ▶ ϕ_1, \dots, ϕ_K をまとめて Φ と書くことにする

混合分布によるデータの生成

- ▶ 混合分布を使ったモデリングでは、 N 個の観測データ $\{\boldsymbol{x}_1, \dots, \boldsymbol{x}_N\}$ が以下のように生成されると仮定する
 1. カテゴリカル分布 $p(z; \boldsymbol{\theta})$ から、確率変数 z_i の値を draw
 2. z_i 番目のコンポーネントを表す確率分布 $p(\boldsymbol{x}|z_i; \boldsymbol{\phi}_{z_i})$ から、 \boldsymbol{x}_i の値を draw
- 注： 確率モデルでデータをモデリングすることとは、データがどのように生成されるかを様々な確率分布を組み合わせで記述することである

混合分布モデルの同時分布

- ▶ 前のスライドで書いたデータの生成を、そのまま式にすると、同時分布の式になる
- ▶ i 番目の観測データ \mathbf{x}_i がどのコンポーネントに属するかを表す確率変数を z_i とする
 - ▶ $z_i = k$ は \mathbf{x}_i が k 番目のコンポーネントに属するという意味
- ▶ すると同時分布 $p(\mathcal{X}, \mathcal{Z})$ は

$$p(\mathcal{X}, \mathcal{Z}) = \prod_{i=1}^N p(z_i; \boldsymbol{\theta}) p(\mathbf{x}_i | z_i; \boldsymbol{\phi}_{z_i}) \quad (1)$$

- ▶ ただし、 $\mathcal{X} \equiv \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, $\mathcal{Z} \equiv \{z_1, \dots, z_N\}$ と定義した
- ▶ 教師なしの設定では、各 z_i は潜在変数

Contents

混合分布モデル

混合分布モデルのベイズ化

例：混合ポアソン分布モデルのベイズ化

混合分布モデルをベイズ化する

- ▶ 事前分布を指定することにより混合分布をベイズ化できる
- 1. コンポーネント選択のカテゴリカル分布に用いる事前分布
 - ▶ z の値が従うカテゴリカル分布 $p(z|\theta)$ には、ディリクレ分布 $p(\theta; \alpha)$ を事前分布として使う
- 2. 各コンポーネントを表す確率分布に用いる事前分布
 - ▶ 各コンポーネントを表す分布 $p(\mathbf{x}|z, \phi_z)$ は k 個ある
 - ▶ これら全てに対して、同じ一つの事前分布 $p(\phi_k; \beta)$ を使う
- ▶ 知りたい事後分布は $p(\theta|\mathcal{X})$ と $p(\phi_k|\mathcal{X})$

復習：ディリクレ分布

- ▶ $\sum_{k=1}^K \theta_k = 1$ を満たす K 個の非負実数 $(\theta_1, \dots, \theta_K)$ の組の集合の上に定義される、連続確率分布
 - ▶ カテゴリカル分布や多項分布の事前分布として使える
- ▶ ディリクレ分布のパラメータは K 個の正の実数 $(\alpha_1, \dots, \alpha_K)$
- ▶ 密度関数の式は

$$p(\boldsymbol{\theta}; \boldsymbol{\alpha}) = \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \theta_k^{\alpha_k - 1} \quad (2)$$




Figure: ディリクレ分布の確率密度関数の例 ($K = 3$)

ベイズ化された混合分布によるデータの生成

- ▶ ベイズ化された混合分布を使ったモデリングでは、 N 個の観測データ $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ が以下のように生成されると仮定
 1. ディリクレ事前分布 $p(\boldsymbol{\theta}; \boldsymbol{\alpha})$ から $\boldsymbol{\theta}$ の値を draw
 2. 事前分布 $p(\boldsymbol{\phi}; \boldsymbol{\beta})$ からコンポーネント K 個分のパラメータ ϕ_1, \dots, ϕ_K を draw
 3. $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ を以下のように draw
 - 3.1 カテゴリカル分布 $p(z|\boldsymbol{\theta})$ から確率変数 z_i の値を draw
 - 3.2 第 z_i コンポーネントの確率分布 $p(\mathbf{x}|z_i, \boldsymbol{\phi}_{z_i})$ から \mathbf{x}_i の値を draw

同時分布

- ▶ 前のスライドで書いたデータの生成を、そのまま式にすると、同時分布の式になる

$$\begin{aligned} p(\mathcal{X}, \mathcal{Z}, \boldsymbol{\theta}, \boldsymbol{\Phi}; \boldsymbol{\alpha}, \boldsymbol{\beta}) \\ = p(\boldsymbol{\theta}; \boldsymbol{\alpha}) \times \prod_{k=1}^K p(\boldsymbol{\phi}_k; \boldsymbol{\beta}) \times \prod_{i=1}^N p(z_i | \boldsymbol{\theta}) p(\boldsymbol{x}_i | z_i, \boldsymbol{\phi}_{z_i}) \end{aligned} \quad (3)$$

ベイズ化された混合分布モデルの教師なし学習

- ▶ 潜在変数 $\mathcal{Z} = \{z_1, \dots, z_N\}$ を周辺化によって消去し…
- ▶ さらにモデルパラメータ θ, Φ も周辺化によって消去し…
- ▶ 観測データの周辺尤度 $p(\mathcal{X}; \alpha, \beta)$ を下のように得る

$$p(\mathcal{X}; \alpha, \beta) = \int p(\theta; \alpha) \prod_{k=1}^K p(\phi_k; \beta) \sum_{\mathcal{Z}} \prod_{i=1}^N p(z_i | \theta) p(\mathbf{x}_i | z_i, \phi_{z_i}) d\theta d\Phi$$

- ▶ そして周辺尤度 $p(\mathcal{X}; \alpha, \beta)$ を最大化する、という問題を解く
 - ▶ 通常は対数周辺尤度 $\ln p(\mathcal{X}; \alpha, \beta)$ を最大化する
- ▶ この最大化問題を解くことで事後分布を近似的に求める

Contents

混合分布モデル

混合分布モデルのベイズ化

例：混合ポアソン分布モデルのベイズ化

混合ポアソン分布モデル

- ▶ 混合ポアソン分布を使ったモデリングでは、 N 個の非負整数からなる観測データ $\{x_1, \dots, x_N\}$ が以下のように生成されると仮定する
 1. カテゴリカル分布 $p(z; \theta)$ から、確率変数 z_i の値を draw
 2. z_i 番目のコンポーネントを表すポアソン分布 $p(x|z_i; \lambda_{z_i})$ から、 x_i の値を draw

ベイズ化された混合ポアソン分布モデル

▶ ベイズ化された混合ポアソン分布を使ったモデリングでは、 N 個の非負整数からなる観測データ $\{x_1, \dots, x_N\}$ が以下のように生成されると仮定する

1. ディリクレ事前分布 $p(\boldsymbol{\theta}; \boldsymbol{\alpha})$ から $\boldsymbol{\theta}$ の値を draw
2. ガンマ事前分布 $p(\lambda; a, b)$ からコンポーネント K 個分のパラメータ $\lambda_1, \dots, \lambda_K$ を draw
3. $\{x_1, \dots, x_N\}$ を以下のように draw
 - 3.1 カテゴリカル分布 $p(z|\boldsymbol{\theta})$ から確率変数 z_i の値を draw
 - 3.2 第 z_i コンポーネントのポアソン分布 $p(x|z_i, \lambda_{z_i})$ から x_i の値を draw